Análisis y predicción de salarios

De los datos a decisiones responsables

Exploración · Estadística · Regresión lineal · Storytelling

Equipo: [Integrante 1] · [Integrante 2] · [Integrante 3 opcional]

Dataset ficticio de nómina en Colombia · Octubre 2026

El problema y la pregunta de investigación

CONTEXTO PROFESIONAL

Un área de Talento Humano necesita entender cómo varían los salarios y evaluar si un modelo puede estimar valores orientativos a partir de información laboral. El análisis no reemplaza la política salarial.

PREGUNTA CENTRAL

¿Cómo se relacionan el nivel de cargo, la experiencia y el departamento con el salario mensual? ¿Una regresión lineal supera una predicción basada solo en la mediana?

Etapa 1 · Origen y estructura de los datos

1.514

filas originales

12

columnas

100%

datos ficticios

Variables: salario mensual COP, nivel de cargo, experiencia, antigüedad, departamento, educación, ciudad, modalidad y horas extra.

Fuente: generación reproducible con Python (semilla 202611). No contiene registros reales, datos personales ni información empresarial.

Etapa 1 · Depuración y control de calidad

1.514
Registros originales

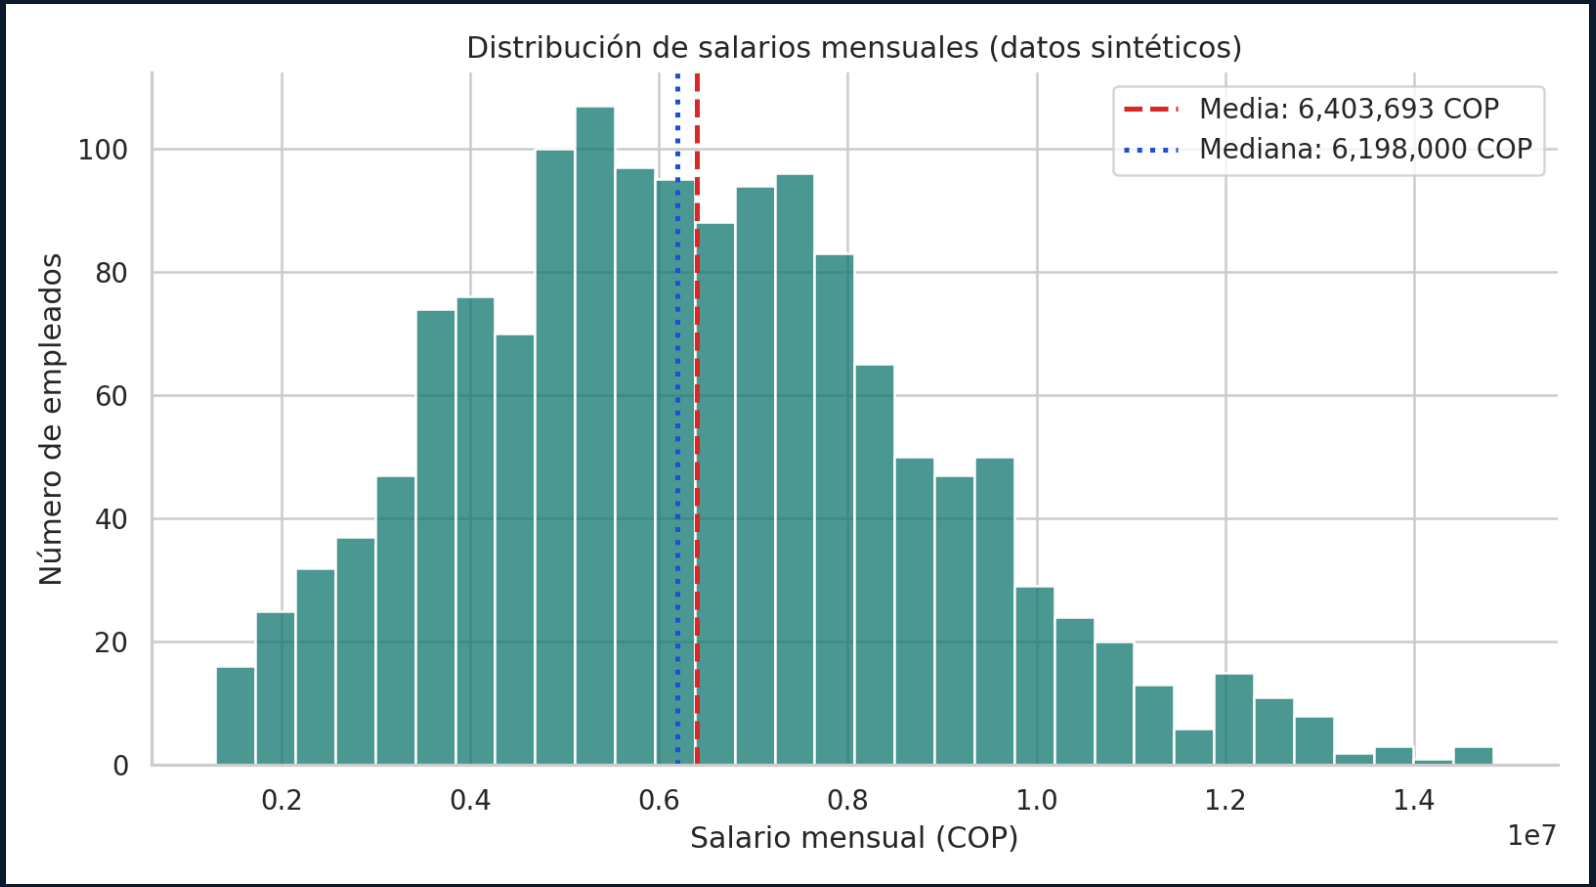
−14
Duplicados exactos

−16
Salarios/edades inválidos

1.484
Registros finales

Además: se estandarizaron etiquetas, se imputaron valores faltantes y se conservaron outliers plausibles.

Etapa 2 · ¿Cómo se distribuyen los salarios?



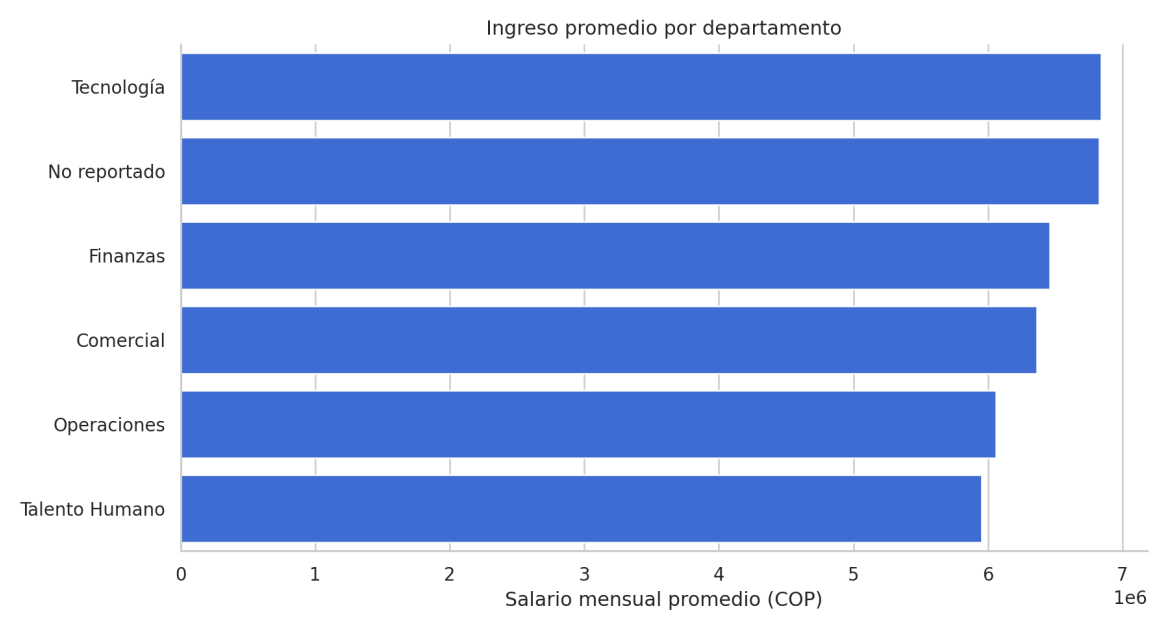
LECTURA

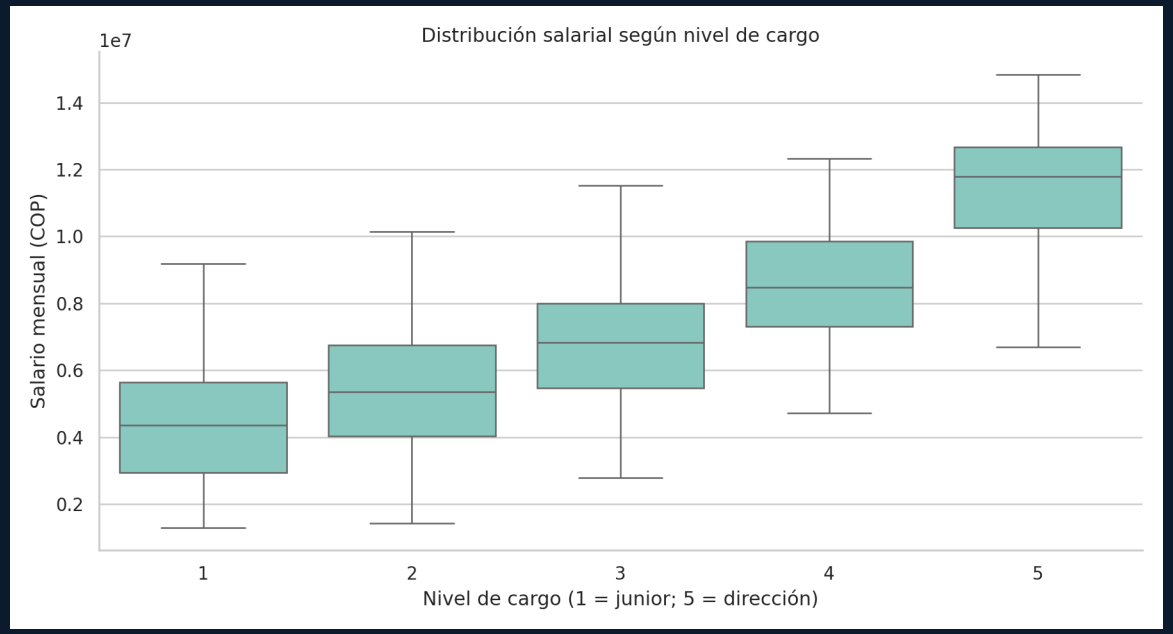
Media: $6,403,693

Mediana: $6,198,000

Se observa dispersión entre salarios; no todos ganan cerca del promedio.

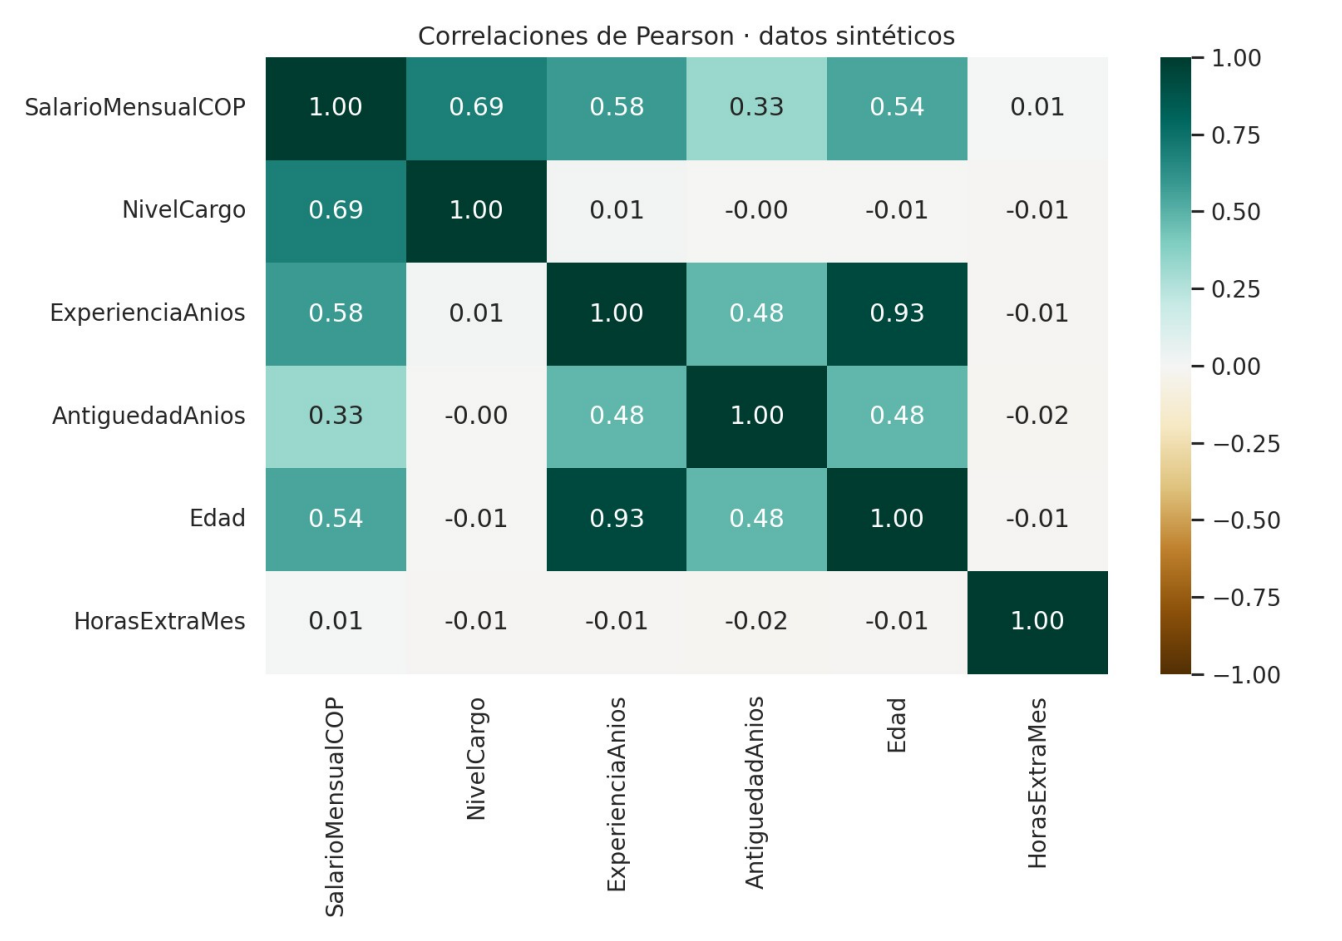
Etapa 2 · Comparación por grupo





Los promedios departamentales también reflejan la composición de cargos.

Etapa 2 · Relaciones e hipótesis



HIPÓTESIS

Nivel de cargo ↔️ salario: r = 0.69.

Experiencia ↔️ salario: r = 0.58.

Correlación no significa causalidad.

Etapa 3 · Diseño de la predicción

1 · PREPARAR

Predictores: cargo, experiencia, antigüedad, departamento, educación, ciudad, modalidad y horas extra. Transformación categórica One Hot.

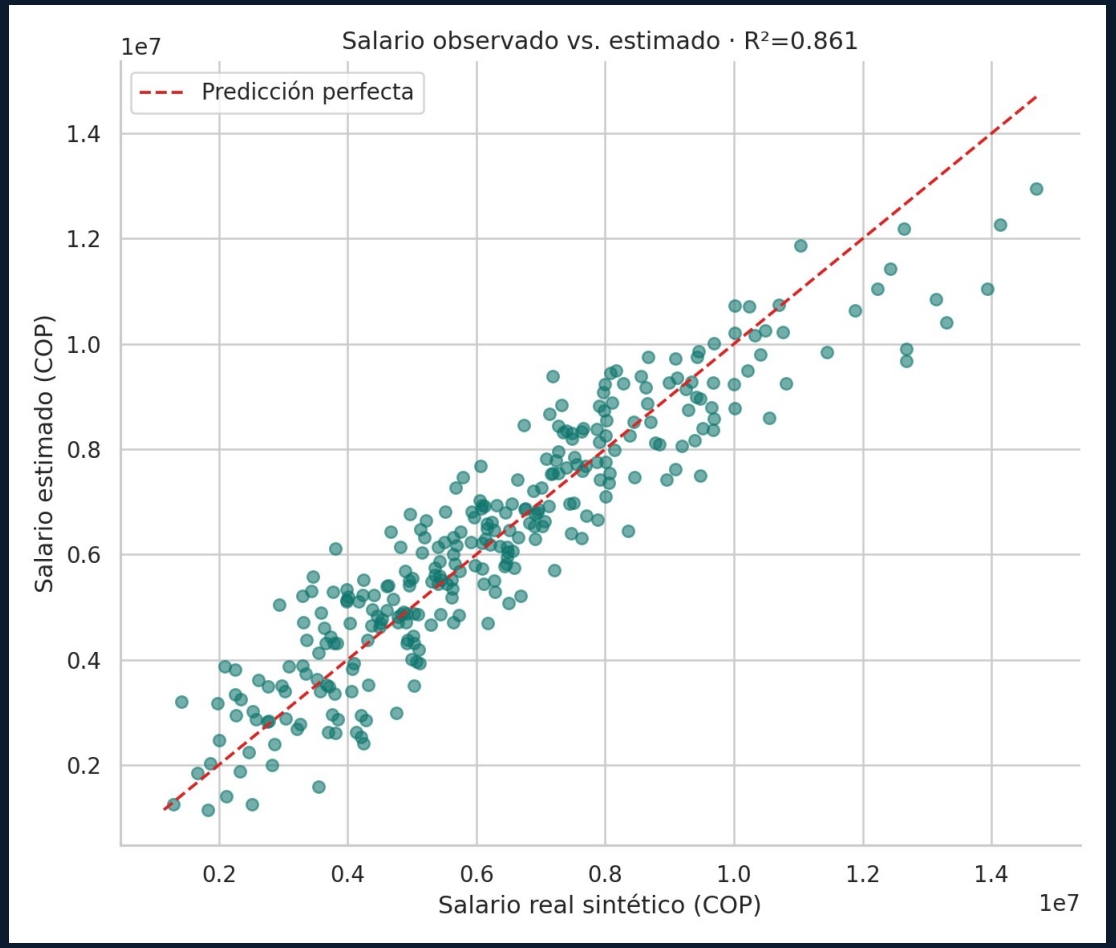
2 · ENTRENAR

1,187 registros (80%) para ajustar regresión lineal. Se compara con el valor mediano del entrenamiento.

3 · EVALUAR

297 registros (20%) reservados. Medimos MAE, RMSE, R^2 y validación cruzada de 5 pliegues.

Etapa 3 · ¿Qué tan bien funcionó?



RESULTADOS

R^2 en prueba: 0.861

MAE del modelo: $764,628

MAE del modelo base: $2,059,364

El modelo mejora al baseline.

Storytelling · De un CSV a una decisión informada

LO QUE APRENDIMOS

La limpieza evita conclusiones engañosas. La estadística resume la dispersión. El modelo necesita compararse con una línea base y evaluarse sobre datos nunca vistos.

APLICACIÓN PROPUESTA

Un prototipo que valide extractos autorizados de SAP HCM y muestre patrones agregados para planeación presupuestaria. Sin decisiones individuales automáticas.

Conclusiones, límites y próximos pasos

CONCLUSIÓN

Se construyó un flujo completo, reproducible y evaluado. El modelo explica parte importante de la variación presente en la simulación.

LÍMITES

Datos sintéticos; sin generalización automática a salarios reales. No inferimos causalidad. Un outlier no es siempre un dato erróneo.

PRÓXIMO PASO

Con permisos y datos anonimizados: validar calidad, vigilar sesgos y contrastar predicciones con especialistas humanos.